



# 훈련 안정성을 위한 병렬 구조의 생성자 기반 GAN

## GAN based on Parallel Generator for Stability Training

2023.11.16 (목)

한국성서대학교 컴퓨터소프트웨어학과 3학년

박범찬(Bumchan Park)



## 0. GAN

### 1. 서론

### 2. 관련 연구 (SNGAN)

## 3. 제안한 방법

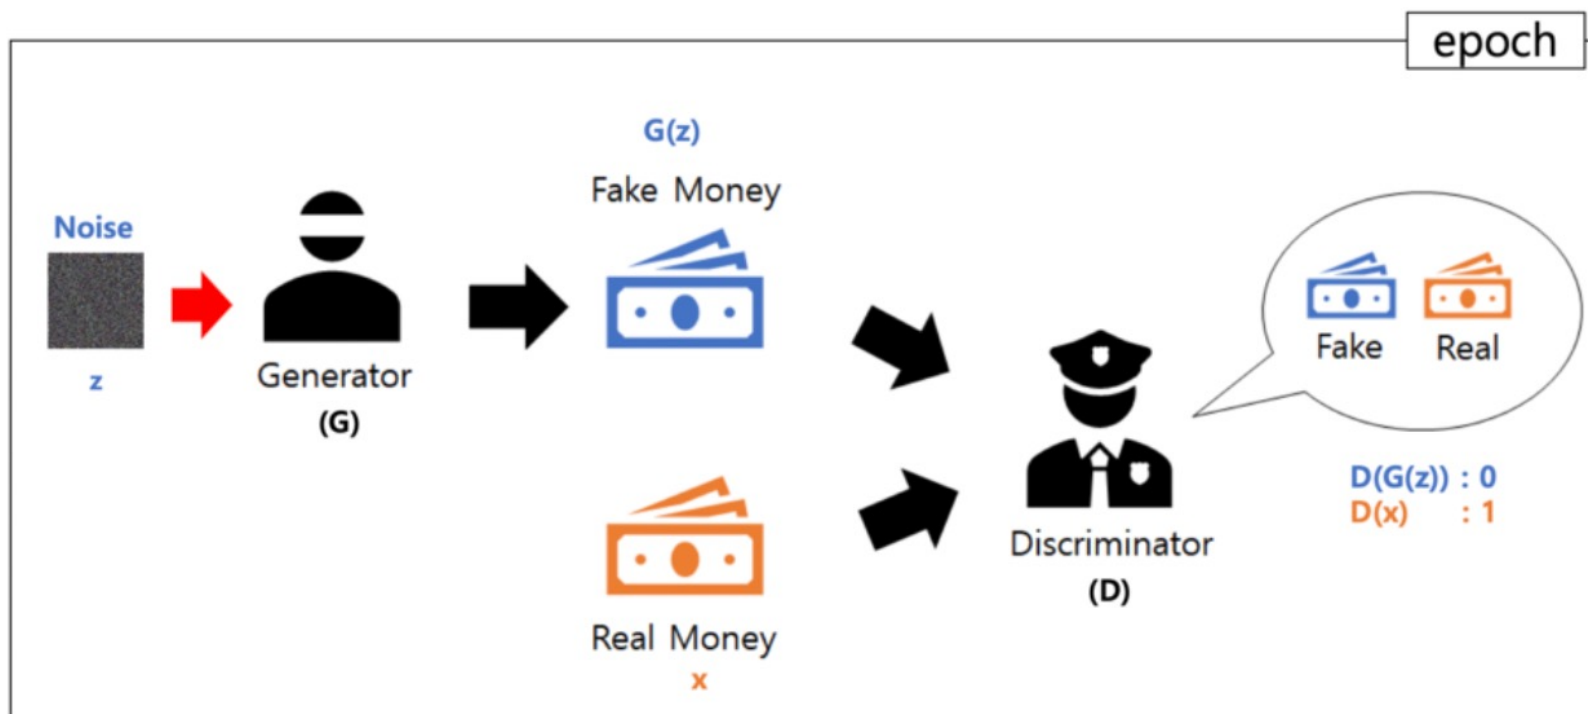
### 3.1 Parallel Generator

### 3.2 Average Loss

## 4. 실험 결과

## 5. 결론

# GAN (Generative Adversarial Network)



## 목적

- 생성자 :  $D(G(z))$ 를 1로 만들기 위함
- 판별자 :  $D(G(z))$ 과  $D(x)$ 를 잘 구분하기 위함

# GAN (Generative Adversarial Network)




$$\min_G \max_D V(D, G) = E_{x \sim p_{data}(x)} [\log D(x)] + E_{z \sim p_z(z)} [\log(1 - D(G(z)))]$$


Generator

$G(z)$ : new data instance

Discriminator


$D(x)$  = Probability: a sample came from the real distribution (Real: 1 ~ Fake: 0)





민감한 정보를 규정하고 있는 만큼, 많은 학습 데이터를 필요로 하는 의료 인공지능 분야  
정보 주체의 프라이버시를 침해하지 않을 수 있는, 규제에서 비교적 자유롭다고 여겨지는 합성데이터

**모드 붕괴 (Mode Collapse) :**  
생성자가 입력 값을 하나의 Mode에 치우쳐 변환시키는 현상



**수렴 (Convergence) :**  
판별자와 생성자 간의 학습이 비슷하게 이뤄지는 지점

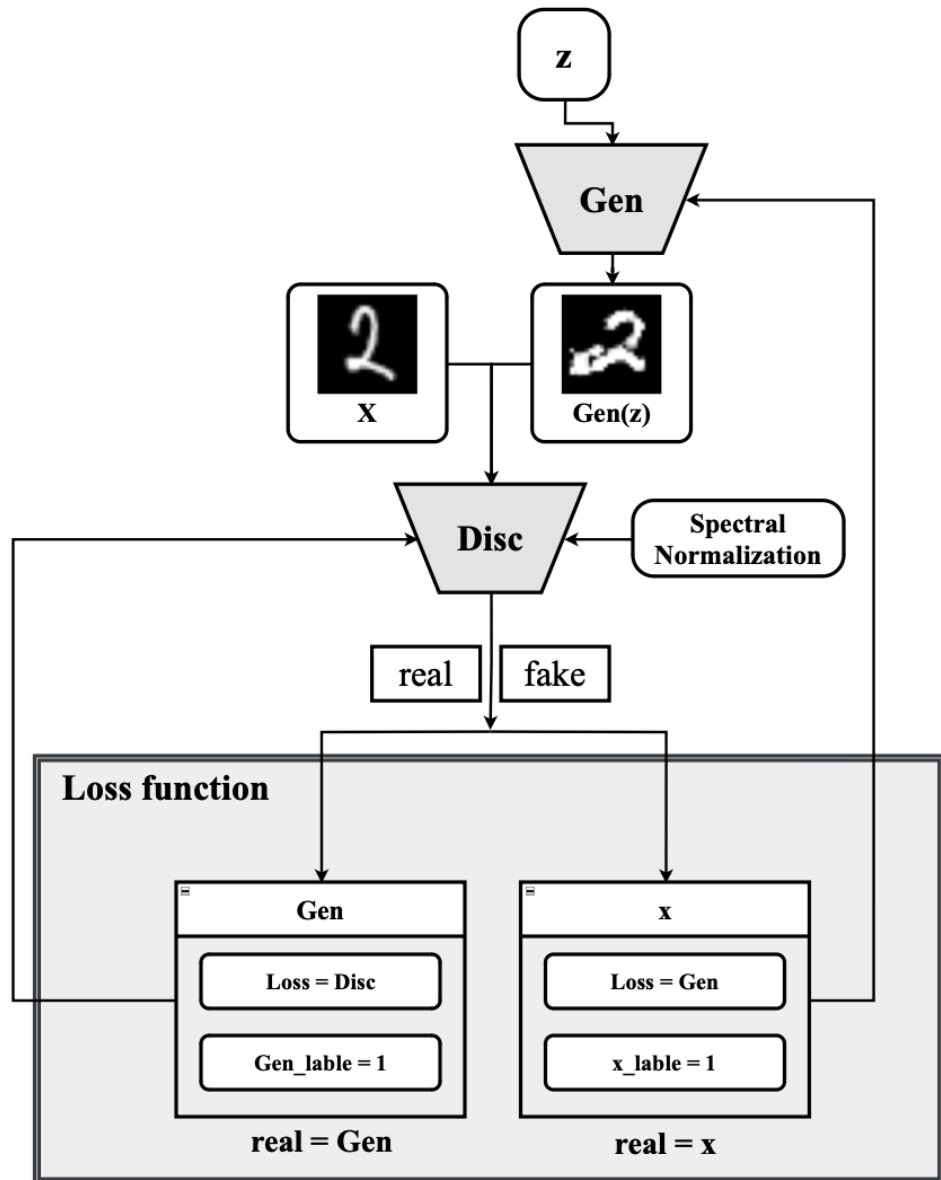
제안 메커니즘 :

1. GAN의 생성자를 두 개로 변형하는 Parallel Generator(병렬 생성자) 형식을 제안
2. Parallel Generator를 통해 얻은 Loss들을 평균을 내어 생성자에 적용하는 방법을 제안

=> GAN에서 발생하는 학습의 불안정성 문제를 해결

=> 생성 모델이 생성한 데이터의 품질이나 성능을 더 발전

# 관련 연구 (SNGAN)



$z$  = 노이즈 벡터

Gen = 생성자

Disc = 판별자

$Gen(x)$  = 거짓 데이터

$x$  = 실제 데이터

GAN이 수렴하기 어려운 이유 :  
첫 번째, 판별자에 제약이 없음  
두 번째, 계산이 불가능함

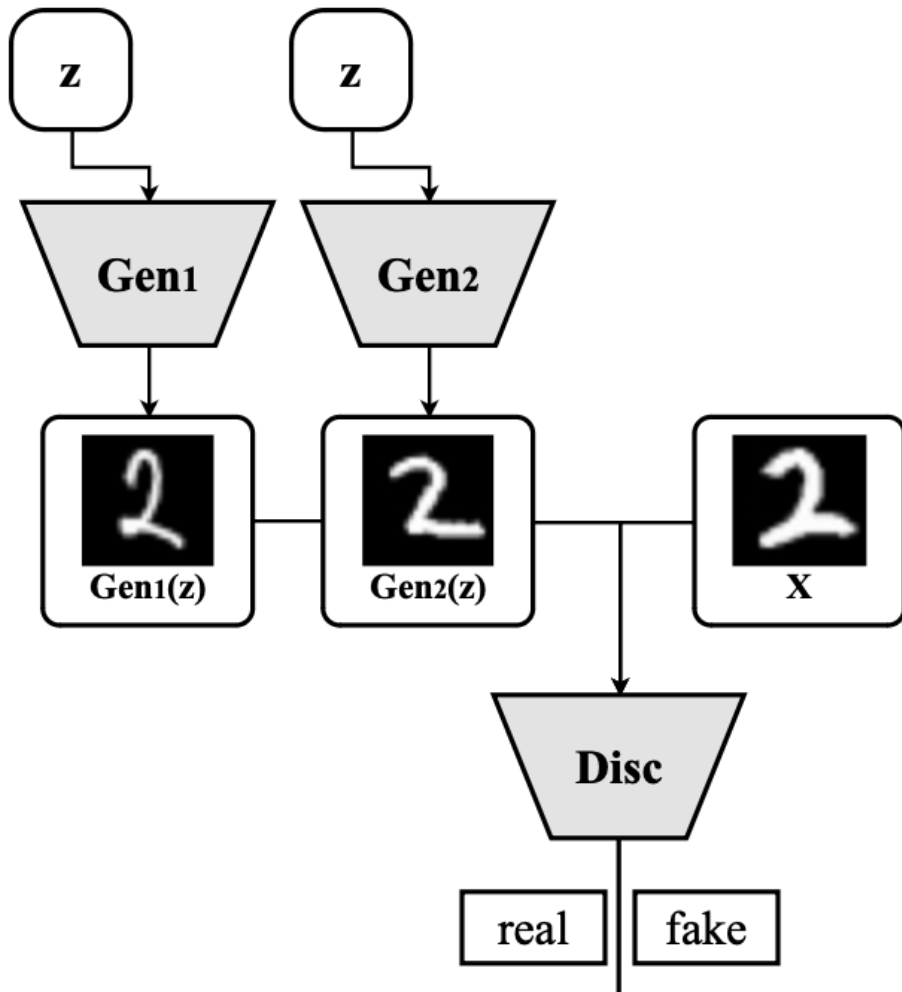
So,  
Disc에 Spectral Normalization을 통해 제약을 두어  
Disc가 Gen에 비해 강해지는 것을 막는 것이 목적!

But,

1. Spectral Normalization의 연산량이 큼
2. 모드 붕괴여부를 정확히 알기 어려움



# 제안한 방법 (Parallel Generator)



Gen1 = 생성자1  
Gen2 = 생성자2

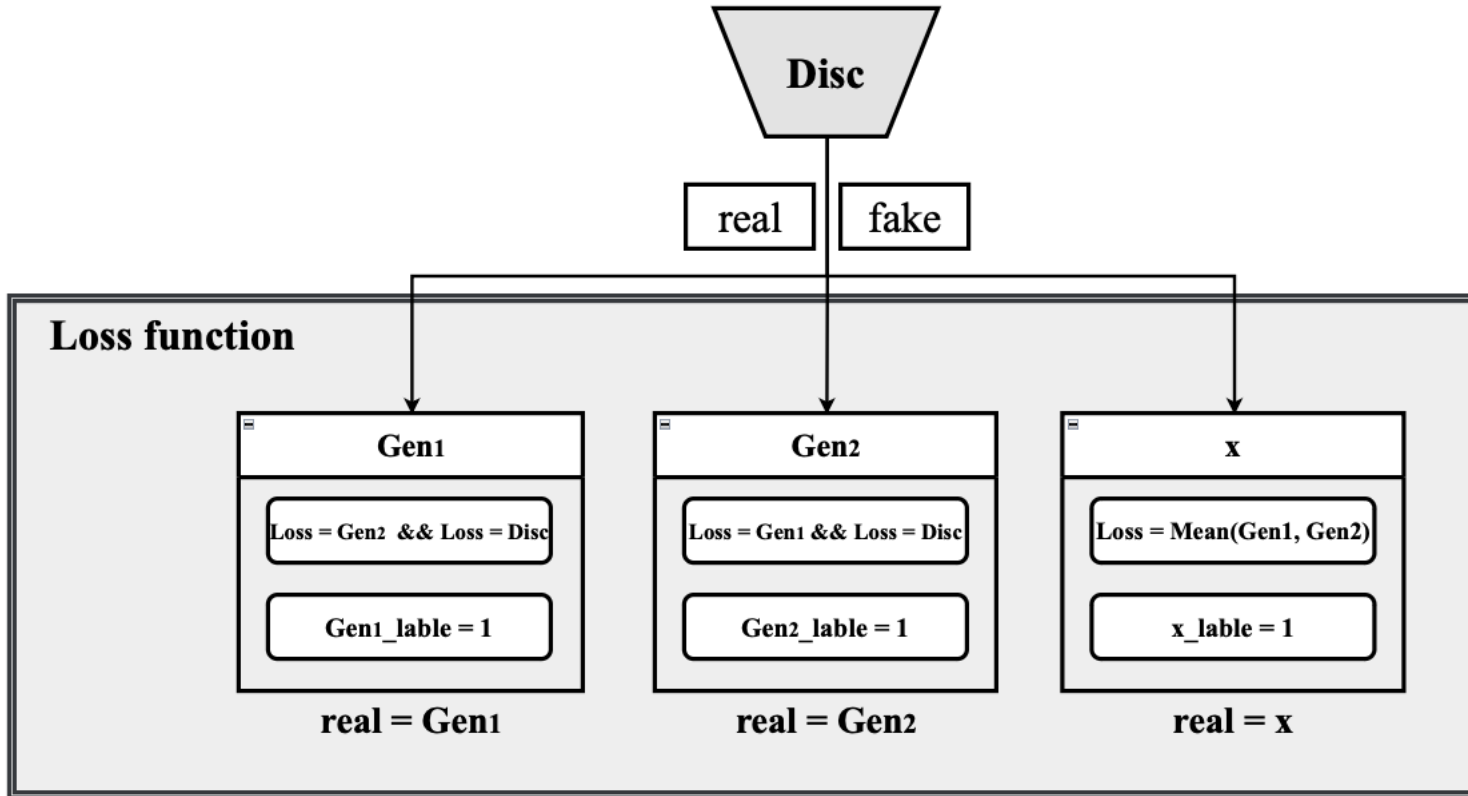
Gen1(z) = 거짓 데이터1  
Gen2(z) = 거짓 데이터2

기존 GAN의 방법론과는 다르게(2개 데이터)  
판별자에 총 세 개의 데이터가 분류기에 진입함

판별자의 분류 :  
real - 1개 / fake - 2개

Disc에 들어가는 데이터의 개수를 늘려  
Disc와 Gen1,2간 균형을 이루는 것이 목적!

# 제안한 방법 (Average Loss)



판별자의 분류 :  
real - 1개 / fake - 2개

Gen1이 real로 판별된 경우 :  
Loss : Gen2, x

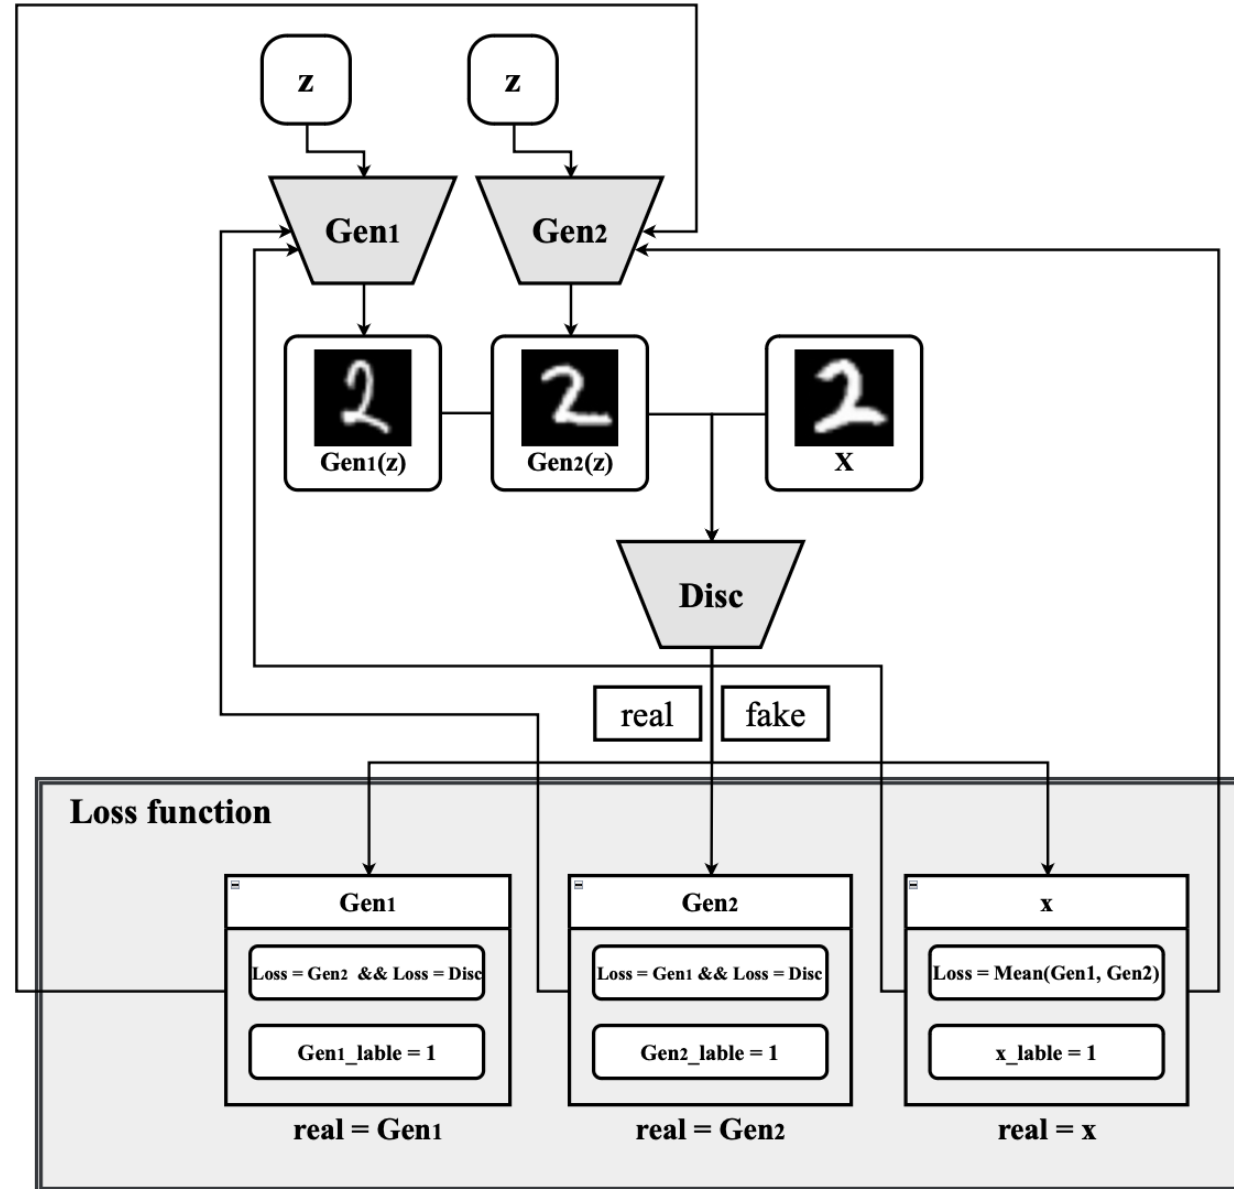
Gen2가 real로 판별된 경우 :  
Loss : Gen1, x

x가 real로 판별된 경우 :  
Loss : Gen1, Gen2의 평균

생성자와 판별자 간의 균형 뿐만 아니라,

두 생성자 간의 균형도 매우 중요함!


# 제안한 방법 (Average Loss)




# 실험 결과



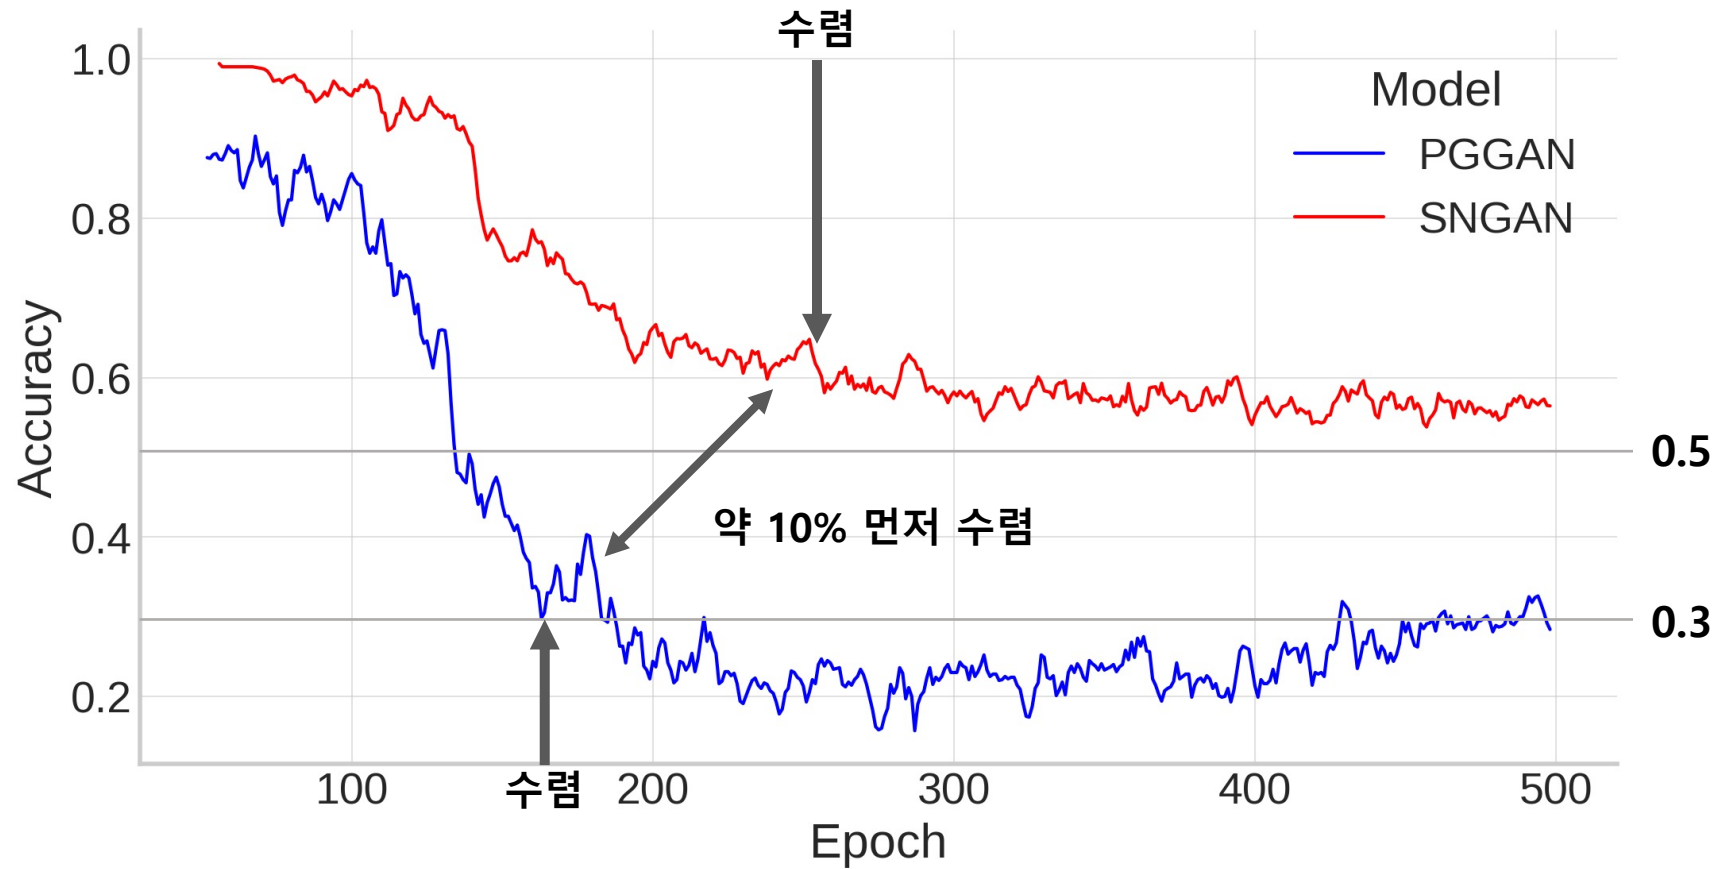
## SNGAN



## PGGAN



# 실험 결과




# 실험 결과



SNGAN



PGGAN





1. PGGAN 알고리즘은 학습 과정에서의 불안정성과 과적합 방지에 탁월한 효과가 있음
2. PGGAN 알고리즘은 생성 데이터의 우수한 성능이 보임을 입증함(몇퍼센트)
3. 정확하고 세밀한 작업을 필요로 하는 의료분야, 빠른 객체의 변화에 대한 인식을 필요로 하는 자율주행 차량 등에서 적절한 방향성을 제시할 수 있을 것
4. 향후에는 학습의 수렴속도에 따른 데이터의 품질과 수렴의 균형을 적절히 고려하여 더욱 안정적인 시스템을 구축하고자 함



**Thank you**