

Original Article Title: Generative Adversarial Networks based on Parallel Structured Generators for Training Stability

To: KMMS 심사위원님

안녕하세요. 심사위원님,

소중한 시간과 노력을 들여 저희 논문을 심사해 주신 것에 대해 진심으로 감사드립니다. "Generative Adversarial Networks based on Parallel Structured Generators for Training Stability"에 통찰력 있는 평가와 제안된 개선 사항에 대하여 더욱 감사드립니다.

3 명의 심사위원님께서 주신 귀중한 피드백은 저희 논문의 완성도를 향상시키는 데 매우 크게 적용되었으며, 제시해 주신 개선 사항들을 깊이 있게 검토하였습니다. 이에 따라, 제안하신 내용을 토대로 논문 수정을 진행하였으며, 3 명의 심사위원 분들의 피드백을 통합하여 아래와 같이 주요 개선 사항을 알려드립니다.

- 「Abstract」 섹션에서 요약문의 길이를 권고사항에 맞춰 작성하였습니다.
- 「SNGAN」 섹션에서 본 연구와 관련된 선행 연구를 조사 및 기재를 통해 GAN 이 가지고 있는 학습의 불안정성 문제에 대한 연구의 필요함을 주장하는 타당성을 높이기 위하여 수정하였습니다.
- 4, 5, 7 페이지에서 전체적인 띄어쓰기 및 어색한 문장을 확인 후 수정하였으며 Table1 를 가운데로 정렬하여 독자들의 이해 및 가독성을 향상하기 위해 노력하였습니다.
- 「실험 결과」 섹션에서 제안하는 방법론과 관련된 정밀도/재현율 실험을 추가하여 PSG 의 근거를 더욱 명확하게 제시하여 미흡함을 보완하고 연구의 타당성을 높이기 위하여 수정하였습니다.
- 「REFERENCE」 섹션에서 3 년 이내의 최신 논문의 참고문헌을 추가하여 본 연구의 신뢰도를 높이고 최신 연구의 동향을 반영하였습니다.

검토자의 답변에 대한 세부적인 답변은 아래 작성된 리뷰에 대한 "**Author action**"을 참고해 주시고 변경된 사항은 원고에 노란색으로 표시하였습니다.

감사합니다.

Reviewer#3, Concern # 1:

Author response: 요약문의 내용이 많음. 7-8 줄 내외 작성 권고

Author action:

Over the past few years, Generative Adversarial Network(GAN) has experienced significant growth in various applications as a generative model. However, the stability issues in training remain a challenge in GANs. To mitigate these problems, this paper proposes a novel GAN model that applies dual-parallelized generators. This study designs new methodologies by inputting three sets of data to the discriminator and updating the average of the loss values. Experimental results show that the proposed model shows an ideal convergence graph and reduces the loss by about 40%. The results also show an improvement in the quality of the generated data, with the model achieving stability during the training process.

권고사항에 맞게 요약 내용을 축소함으로 가독성을 높이기 위하여 수정하였습니다. (Abstract, p.1 참조)

Reviewer#3, Concern # 2:

Author response: 2 장에서 관련 연구분석이 필요해 보임. 유사 문헌에 대한 분석이 필요함

Author action:

모델의 크기가 클수록 Spectral Norm 을 계산하기 위해 더 많은 Power Iteration 단계가 필요하게 되고 이는 전체 훈련 시간에 영향을 미친다. 결국 정규화 기법은 판별자의 구별 능력을 제한할 수 있으며, 전반적인 이미지 품질에 부정적인 영향을 미치고 샘플 생성을 방해할 수 있다[17].

결론적으로, SNGAN 에서 SN 을 활용하는 것은 훈련의 안정성을 보장하지만 계산 비용이라는 문제점을 동반한다. SNGAN 과 관련 연구는 고해상도 출력과 업 스케일링(up-scaling)에 대한 연구로 발전하고 있는 반면[18][19][20], 학습의 불안정성과 과적합 문제의 연구는 완전히 개선되었다고 보기엔 무리가 있다. 이러한 종합적인 문제를 해결하기 위해 지속적인 연구가 필요하다.

본 논문의 2 장에서 정규화 기법은 판별자의 구별 능력을 제한할 수 있으며, 전반적인 이미지 품질에 부정적인 영향을 미치는 한계가 존재함에 대한 설명을 추가하였습니다. 또한, SNGAN 과 관련된 연구는 고해상도와 업 스케일링에 대한 연구로 발전하는 반면, 학습의 불안정성에 대한 연구가 확실하게 이루어지지 않고 있다는 점을 고려해 PSG-GAN 알고리즘에 대한 연구의 필요성을 일관성 있는 흐름을 위해 추가로 기재하여 논문을 수정하였습니다. (2. Spectral Normalization GAN(SNGAN), p.3 참조)

Reviewer#3, Concern # 3:

Author response: 단순한 실험결과를 추가하여 유사 연구에 대한 연구부헌과의 비교 연구가 필요함

Author action: 본 논문에서는 제안하는 PSG-GAN 이 제안하는 알고리즘의 정밀도/재현율 실험 결과 Table 을 추가하였습니다. Table. 2 는 SNGAN 과 PSG-GAN 의 수렴 이후 정밀도와 재현율의 평균을 나타냅니다.

Table. 2. Comparison Precision and Recall

Model Index	SNGAN	PSG-GAN
Precision	0.4816	0.6871
Recall	0.4136	0.6398

정밀도는 모델이 True 라고 분류한 것 중에서 실제 True 인 것의 비율이며, 재현율은 실제 True 인 것 중에서 모델이 True 라고 예측한 것의 비율입니다. 정밀도와 재현율은 서로 상호보완적으로 사용해야 하며, 두 지표가 모두 높을수록 좋은 모델입니다. PSG-GAN 의 정밀도는 0.6871 로 SNGAN 에 비해 약 42.6% 향상되었고 재현율 또한 0.6398 로 SNGAN 과 대비해 약 54.7% 개선되었습니다. 이러한 실험 결과를 통해 PSG-GAN 알고리즘이 실제와 유사한 이미지를 더욱 안정적으로 생성하여 더 넓은 범위의 데이터 분포를 포착할 수 있음을 표현합니다. 이를 통해, PSG-GAN 알고리즘의 연구 가치가 높으며 훈련의 불안정성을 완화하는 것에 대한 타당성이 높음을 입증하기 위해 논문을 수정하였습니다. (4.5 정밀도 재현율 비교, p.7 참조)

Reviewer#3, Concern # 4:

Author response: 최신 참고문헌 추가 필요

Author action: 본 논문에서는 해당 PSG-GAN 알고리즘이 최신 연구 동향을 반영한 신뢰도 높은 논문임을 증명하기 위해서 3 년 이내의 자료들을 참고문헌에 추가하였습니다. 최신 참고문헌을 사용함으로써, 이 연구가 현재의 학문적 연구 방향성에 어떻게 기여하는지를 보여줄 수 있으며 현재 GAN 이 가지고 있는 문제와 관련되어 있음을 보강하여 설명하였습니다. (REFERENCE, p.8-9 참조)
